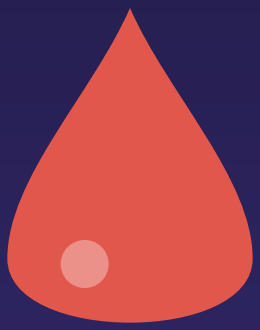
UPA

UNIVERSIDAD POLITÉCNICA
DE ATLAUTLA

FUNDAMENTOS DE
INTELIGENCIA ARTIFICIAL
GRUPO G171



ACTIVIDAD INTEGRADORA 3.1 · SECCIONES 1 Y 2

Del dato
al bien social

Modelos de inteligencia artificial para transformar realidades: el caso del acceso al agua potable.

Problemática del equipo · Acceso al agua potable

ASIGNATURA
Fundamentos de Inteligencia Artificial

DOCENTE
Mtro. Javier García Lara

GRUPO / PERIODO
G171 · Cuatrimestre 7 · Sep–dic 2026

ENTREGA
5 de noviembre de 2026

MODALIDAD
Investigación y modelado · Secciones 1 y 2

INSTITUCIÓN
Universidad Politécnica de Atlautla

INTEGRANTES DEL EQUIPO

Bernal Najera Alexandra
Marin Flor Julissa
Rosas Toriz Erandy Naomy
Suarez Melonie Magdalena
Aguilar Bello Rogerio

"El agua no se crea ni se destruye: se cuida, se mide y se decide."

ACTIVIDAD EN EQUIPO · DOCUMENTO DIGITAL

FIA · 2026

MAPA DEL DOCUMENTO

Contenido

Actividad Integradora 3.1 · Secciones 1 y 2 · Acceso al agua potable

Planteamiento del problema y ruta de lectura . . . 3

Sección 1 · Investigación . . . 4

1.1 Concepto de aprendizaje automático . . . 5

1.2 Clasificación del aprendizaje automático y aplicaciones . . . 8

1.3 Contexto y oportunidad: del dato hídrico a la decisión . . . 10

1.4 Conclusiones de la Sección 1 . . . 12

1.5 Referencias y declaración de uso de IA . . . 13

Sección 2 · Modelados . . . 14

2.1 Grafo de taxonomía del aprendizaje automático . . . 15

2.2 Diagrama de flujo del ciclo de vida de un modelo . . . 17

2.3 Tabla comparativa de métricas de evaluación . . . 18

2.4 Formalización matemática del aprendizaje . . . 21

2.5 Conclusiones de la Sección 2 . . . 23

2.6 Referencias y declaración de uso de IA . . . 24

03 Conclusiones generales . . . 25

04 Referencias consolidadas (APA 7) . . . 26

05 Anexo A. Roles del equipo y declaración de originalidad . . . 27

06 Anexo B. Diagramas y tablas complementarios . . . 29

CÓMO LEER ESTE DOCUMENTO

La **Sección 1** responde qué es el aprendizaje automático, cómo se clasifica y dónde se aplica. La **Sección 2** lo traduce en grafos, diagramas, métricas y modelos formales. El hilo conductor es la problemática del equipo: el acceso al agua potable. Las referencias siguen el formato APA 7 y cada sección cierra con su declaración de uso de inteligencia artificial. El **Anexo B** añade diagramas de flujo, una arquitectura de datos y tablas complementarias.

PRODUCTO DE LA ACTIVIDAD

Documento digital en PDF con portada, índice, contenido, conclusiones y referencias. Las figuras y tablas son de elaboración propia; los datos provienen de las fuentes citadas. La Sección 3 se entrega por separado, a mano, conforme a las instrucciones de la actividad.

APERTURA · 00

Planteamiento del problema y ruta de lectura

El acceso al agua potable no es solo un problema de tuberías: es también un problema de información. Una red de agua produce cada día millones de datos —presión, caudal, consumo, calidad, reportes ciudadanos— que rara vez se convierten en decisiones para anticipar fallas, reducir pérdidas y priorizar a quienes tienen el servicio más frágil. Esta actividad explora cómo el aprendizaje automático puede ayudar a cerrar esa brecha entre el dato y el bien social.

2.1 mil M
personas sin servicios de agua potable gestionados de forma segura en 2024.
WHO y UNICEF (2025)

106 M
personas que todavía beben directamente de aguas superficiales.
WHO y UNICEF (2025)

40 %
del agua potable doméstica se pierde por fugas en el Valle de México (más 10 % no contabilizado).
Zavala (2024)

96.1 %
de cobertura nacional de agua potable en México (Censo 2020); la brecha está en calidad y continuidad.
CONAGUA (2024)

¿Dónde están las personas sin agua segura?

Población mundial · 2024 · 8.2 mil millones de personas



Figura 0.1. Composición de la población mundial según el tipo de servicio de agua potable en 2024. Elaboración propia con datos de WHO y UNICEF (2025). Los porcentajes pueden no sumar 100 % por redondeo.

PREGUNTA GUÍA DEL EQUIPO

¿Qué tipo de aprendizaje automático permite transformar los datos operativos y socioambientales de un sistema de agua potable en decisiones que reduzcan pérdidas y mejoren la equidad del servicio?

Objetivos del documento

	Objetivo	Qué se logra
1	**Comprender**	Explicar qué es el ML, en qué se diferencia de la programación tradicional y cuáles son sus conceptos básicos.
2	**Clasificar**	Distinguir los cinco tipos de aprendizaje y reconocer al menos diez aplicaciones reales.
3	**Modelar**	Representar la taxonomía en un grafo, describir el ciclo de vida, comparar métricas y formalizar el problema.
4	**Argumentar**	Vincular los modelos con el acceso al agua potable: fugas, calidad y priorización equitativa.

RUTA DE LECTURA

La Sección 1 construye el marco conceptual; la Sección 2 lo convierte en gráficos y modelos formales; las conclusiones anticipan la Sección 3, que se entrega a mano según las instrucciones del docente.

SECCIÓN 01
INVESTIGACIÓN

01

Investigar para comprender

Qué es el aprendizaje automático, de dónde viene su capacidad de aprender, cómo se clasifica y dónde ya está transformando el acceso al agua potable.

1.1 Concepto y conceptos clave

1.2 Clasificación y aplicaciones reales

1.3 Contexto: del dato hídrico a la decisión

1.4 Conclusiones de la sección

1.5 Referencias y declaración de IA

"Un programa aprende de la experiencia E con respecto a una tarea T y una medida de desempeño P si su desempeño en T, medido por P, mejora con E."

TOM MITCHELL · MACHINE LEARNING (1997)

SECCIÓN 1 · 1.1 · INVESTIGACIÓN CONCEPTUAL

Concepto de aprendizaje automático

Antes de elegir un algoritmo conviene responder una pregunta más básica: ¿qué significa que una máquina “aprenda”? La respuesta no es un truco de programación, sino un cambio de paradigma: en lugar de escribir todas las reglas, se le entregan ejemplos y se le pide encontrar el patrón.

1.1.1 ¿Qué es el aprendizaje automático?

El aprendizaje automático (*machine learning*, ML) es una rama de la inteligencia artificial que construye programas capaces de mejorar su desempeño en una tarea a partir de la experiencia contenida en datos. En lugar de que una persona programe cada regla, el sistema ajusta un modelo —una función con parámetros— para que sus predicciones se acerquen a los resultados observados. Esa cercanía se mide con una **función de pérdida** y se mejora mediante un proceso de **optimización**.

La definición clásica de Mitchell (1997) sigue siendo una de las más precisas porque obliga a nombrar tres cosas: la tarea, la experiencia y la medida de desempeño. Sin esas tres, no hay aprendizaje verificable. Géron (2022) lo resume como la ciencia de programar computadoras para que aprendan a partir de datos, mientras que IBM (2024) lo describe como el uso de datos y algoritmos para imitar la forma en que aprenden las personas y mejorar gradualmente la precisión. Las tres definiciones coinciden en un punto: el conocimiento no se escribe, se estima a partir de evidencia.

Fuente	Definición (traducción propia)	Énfasis
Mitchell (1997)	Un programa aprende de la experiencia E con respecto a una tarea T y una medida de desempeño P si su desempeño en T, medido por P, mejora con E.	Tarea, experiencia y métrica explícitas.
Géron (2022)	La ciencia de programar computadoras para que puedan aprender a partir de datos.	Datos como fuente de aprendizaje.
IBM (2024)	Rama de la IA y las ciencias de la computación centrada en usar datos y algoritmos para imitar la forma en que aprenden los humanos, mejorando gradualmente la precisión.	Mejora iterativa y automatización.

> DEFINICIÓN PROPIA DEL EQUIPO
>
> El aprendizaje automático es una disciplina de la inteligencia artificial que permite que un sistema ajuste sus parámetros a partir de ejemplos y mejore su desempeño en una tarea medible, en lugar de recibir instrucciones explícitas para cada caso. Su valor no está en “pensar” como una persona, sino en encontrar regularidades en datos que serían difíciles de escribir como reglas y en actualizarlas cuando el entorno cambia.

Programación tradicional vs. aprendizaje automático

La diferencia esencial está en la dirección del conocimiento. En la programación tradicional, la persona conoce la regla y la escribe; en el aprendizaje automático, la persona proporciona ejemplos y el sistema estima la regla. Esto no significa que el ML sea siempre mejor: si la regla es clara, estable y verificable, programarla suele ser más barato, auditable y seguro.

PROGRAMACIÓN TRADICIONAL

Reglas + datos

El equipo escribe la lógica del negocio.

→

RESULTADO

Respuestas

La computadora ejecuta la regla y devuelve una salida.

APRENDIZAJE AUTOMÁTICO

Datos + respuestas

Se muestran ejemplos de entrada y salida deseada.

→

RESULTADO

Modelo (reglas estimadas)

La computadora generaliza a casos nuevos.

Dimensión	Programación tradicional	Aprendizaje automático
Entrada	Reglas + datos.	Datos + ejemplos de la respuesta correcta (etiquetas).
Proceso	Algoritmo explícito, escrito por una persona.	Ajuste de parámetros mediante optimización.
Salida	Una respuesta calculada.	Un modelo que generaliza a datos no vistos.
Ejemplo en agua	Calcular la tarifa con una fórmula y un tabulador.	Estimar la probabilidad de fuga en un tramo de tubería.
Mantenimiento	Se corrige la regla cuando cambia el proceso.	Se reentrena el modelo cuando cambian los datos.
Riesgo típico	Reglas incompletas o desactualizadas.	Sesgo, sobreajuste, deriva de datos y opacidad.
Cuándo usarlo	Reglas claras, estables y auditables.	Patrones complejos, cambiantes o difíciles de escribir.

ERROR FRECUENTE

Pensar que “más datos” siempre equivale a “mejor modelo”. Un dataset pequeño pero representativo y bien etiquetado puede superar a millones de registros sesgados. La calidad, la pertinencia y la forma de medir importan tanto como el volumen.

1.1.2 Dataset, etiqueta, feature y función de pérdida

Cuatro conceptos aparecen en casi cualquier proyecto de ML. Conviene entenderlos con un ejemplo cercano: un operador de agua potable quiere saber si una muestra es apta para consumo humano.

Concepto	Definición	Ejemplo en acceso al agua potable
Dataset	Conjunto organizado de ejemplos. Cada fila es una observación y cada columna una variable. Se divide en entrenamiento, validación y prueba.	12,000 registros de sensores de calidad: pH, turbiedad, cloro residual, temperatura y la decisión sanitaria correspondiente.
Feature (variable, atributo)	Característica medible que describe al ejemplo. Es la entrada x del modelo; puede ser numérica, categórica, temporal o espacial.	pH, turbiedad, conductividad, presión, caudal, edad de la tubería, material, clima, consumo histórico.
Etiqueta (target)	Respuesta que el modelo debe aprender a predecir. Es la salida y; solo existe en aprendizaje supervisado.	“Potable / no potable”, “fuga / no fuga”, litros consumidos, probabilidad de falla en los próximos 30 días.
Función de pérdida L	Medida del error entre la predicción y la etiqueta. El entrenamiento busca los parámetros que la minimizan.	Entropía cruzada para decidir si el agua es potable; error cuadrático medio para pronosticar la demanda.

FUNCIONES DE PÉRDIDA

MSE (regresión): $L(y, \hat{y}) = (1/n)\ \Sigma_{i=1..n}\ (y_i - \hat{y}_i)^2$

Penaliza con fuerza los errores grandes; se usa con variables continuas como litros por segundo o demanda diaria.

Entropía cruzada binaria (clasificación):

$L(y, \hat{y}) = -(1/n)\ \Sigma_{i=1..n}\ [\ y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)\ ]$

Penaliza las probabilidades seguras pero equivocadas; es la pérdida típica para “potable / no potable” o “fuga / no fuga”.

PÉRDIDA NO ES LO MISMO QUE MÉTRICA

La pérdida guía el entrenamiento y debe ser diferenciable para optimizar. La métrica evalúa el resultado con el lenguaje del problema: exactitud, recall, F1, error absoluto medio o costo económico. Un modelo puede tener baja pérdida y, aun así, ser inútil si la métrica elegida no refleja la decisión real. En fugas, por ejemplo, un recall alto es más importante que una exactitud global alta, porque dejar pasar una fuga suele costar más que revisar una falsa alarma.

¿Cómo se ve un proyecto de ML en la práctica?

El modelo es solo una parte. Antes hay que definir la pregunta, conseguir datos representativos, limpiarlos y dividirlos; después hay que evaluar, ajustar, desplegar y monitorear. La Sección 2 desarrolla ese ciclo de vida con detalle. Por ahora basta retener una idea: el aprendizaje automático es un proceso sociotécnico, no solo un algoritmo.

IDEA CLAVE

Un buen dataset no es el más grande, sino el que representa el problema y contiene las variables que explican la decisión. Si los datos de una zona rural no aparecen en el entrenamiento, el modelo puede ser muy preciso en promedio y, al mismo tiempo, invisible para quienes más necesitan el servicio.

SECCIÓN 1 · 1.2 · TIPOS Y APLICACIONES

Clasificación del aprendizaje automático

Los tipos de aprendizaje se distinguen por la señal disponible: si hay etiquetas, si solo hay datos, si existe una recompensa o si el conocimiento se reutiliza desde otro dominio. Elegir el tipo correcto es más importante que elegir el algoritmo de moda.

1.2.1 Los cinco grandes tipos

Tipo	Señal de aprendizaje	Tareas típicas	Algoritmos representativos	Ejemplo en agua potable
Supervisado	Pares (entrada, etiqueta). Se conoce la respuesta correcta.	Clasificación y regresión.	KNN, SVM, árboles, Random Forest, regresión lineal y logística.	Predecir fuga / no fuga en un tramo; estimar la demanda diaria.
No supervisado	Solo entradas, sin etiqueta. El modelo busca estructura.	Clustering, reducción de dimensionalidad y asociación.	K-Means, DBSCAN, jerárquico, PCA, t-SNE, Apriori.	Segmentar usuarios por patrón de consumo; detectar consumos atípicos.
Por refuerzo	Recompensa o castigo tras cada acción; no hay etiqueta directa.	Toma secuencial de decisiones y control.	Q-Learning, SARSA, DQN, PPO.	Programar bombas y válvulas para minimizar energía sin perder presión.
Semisupervisado	Pocas etiquetas y muchos datos sin etiqueta.	Clasificación con etiquetado costoso.	Self-training, label propagation, co-training.	Clasificar calidad del agua con pocos análisis de laboratorio.
Transferencia	Conocimiento de un dominio fuente aplicado a un dominio destino.	Fine-tuning y extracción de características.	LoRA, ajuste de capas, feature extraction.	Adaptar un modelo de fugas entrenado en una ciudad a otra red.

CÓMO ELEGIR EL TIPO

Primero se pregunta qué se quiere predecir y qué información existe. Si hay etiquetas confiables, el punto de partida es el aprendizaje supervisado. Si no las hay, se explora estructura con clustering o reducción de dimensionalidad. Si la decisión cambia el estado del sistema y recibe retroalimentación, el marco natural es el aprendizaje por refuerzo. Si el etiquetado es caro, el semisupervisado o la transferencia pueden reducir el esfuerzo.

1.2.2 Aplicaciones reales

La tabla reúne trece aplicaciones documentadas en operadores, literatura científica y plataformas de datos. Se indica el tipo de aprendizaje, la tarea y el nivel de madurez para distinguir entre sistemas comerciales, pilotos, uso extendido e investigación aplicada.

#	Aplicación	Tipo · tarea	Qué aprende / variable objetivo	Madurez y caso
01	**Detección acústica de fugas**	Supervisado · clasificación	Decide fuga / no fuga a partir de audio y vibración de sensores; estima el tamaño para priorizar la reparación.	COMERCIAL FIDO AI (Reino Unido)
02	**Predicción de fallas de tubería**	Supervisado · clasificación	Probabilidad de falla en los próximos meses según edad, material, suelo, presión e historial de reparaciones.	USO EXTENDIDO Operadores de agua
03	**Pronóstico de demanda**	Supervisado · regresión	Demanda horaria o diaria en m³ a partir de consumo histórico, clima, calendario y actividad económica.	USO EXTENDIDO Servicios municipales

#	Aplicación	Tipo · tarea	Qué aprende / variable objetivo	Madurez y caso
04	**Calidad del agua potable**	Supervisado · clasificación	Probabilidad de que una muestra sea apta para consumo con pH, turbiedad, cloro residual, conductividad y sólidos.	PROTOTIPOS Dataset Water Potability
05	**Mantenimiento predictivo de bombas**	Supervisado · clasificación / regresión	Falla o vida útil restante a partir de vibración, temperatura, corriente y horas de operación.	PILOTOS Industria del agua
06	**Segmentación de usuarios**	No supervisado · clustering	Grupos de hogares o comercios con patrones de consumo similares para tarifas, campañas y equidad.	USO EXTENDIDO Organismos operadores
07	**Detección de anomalías de consumo**	No supervisado · anomalías	Identifica consumos atípicos compatibles con fugas, fraude o errores de medición sin necesidad de etiquetas.	USO EXTENDIDO Medición inteligente
08	**Reducción de variables de monitoreo**	No supervisado · PCA	Resume decenas de sensores correlacionados en pocos componentes que explican la mayor parte de la variabilidad.	INVESTIGACIÓN Calidad de cuencas
09	**Monitoreo satelital de cuerpos de agua**	Deep learning · segmentación	Máscaras de agua y cambios de superficie a partir de imágenes satelitales y series temporales.	OPERACIÓN GLOBAL JRC Global Surface Water
10	**Programación de bombas y energía**	Refuerzo · control secuencial	Política de encendido y apagado que minimiza costo eléctrico y emisiones sin comprometer la presión.	PILOTOS Redes de distribución
11	**Contaminantes con pocas etiquetas**	Semisupervisado · clasificación	Combina pocos análisis de laboratorio con muchos registros de sensores para ampliar la cobertura de detección.	INVESTIGACIÓN Calidad del agua
12	**Adaptación entre ciudades**	Transferencia · fine-tuning	Reutiliza un modelo entrenado en una red y lo ajusta con datos locales para otra ciudad o tipo de tubería.	INVESTIGACIÓN Modelos de fugas
13	**Asociación de eventos operativos**	No supervisado · reglas de asociación	Descubre combinaciones de presión, clima, mantenimiento y reportes que suelen preceder una falla.	INVESTIGACIÓN Analítica de redes

Nota de verificación. Los casos 01, 04 y 09 se sustentan en FIDO Tech (2024), Kadiwal (2023) y Pekel et al. (2016), respectivamente. Los demás describen prácticas documentadas en la literatura y en la operación de servicios de agua; no se atribuyen cifras de desempeño que no hayan sido publicadas por una fuente verificable.

LECTURA CRÍTICA

“Aplicación real” no significa “solución probada en todas partes”. Un modelo de fugas entrenado con tuberías de PVC y presión estable puede fallar en una red con tuberías antiguas, intermitencia y baja instrumentación. La madurez tecnológica debe leerse junto con la calidad de los datos y la capacidad institucional para actuar sobre las alertas.

SECCIÓN 1 · 1.3 · PROBLEMÁTICA DEL EQUIPO

Contexto y oportunidad: del dato hídrico a la decisión

El acceso al agua potable combina infraestructura, salud pública, economía y justicia social. El aprendizaje automático no reemplaza ninguna de esas dimensiones: las conecta con evidencia. Su mayor oportunidad está en pasar de la **reacción** (reparar lo que ya falló) a la **anticipación** (priorizar lo que está por fallar y proteger a quien tiene menos margen).

La dimensión sanitaria explica la urgencia. La Organización Mundial de la Salud (2023) estima que aproximadamente 505 000 muertes por diarrea al año se asocian a agua contaminada microbiológicamente y que, en 2022, al menos 1 700 millones de personas utilizaban una fuente contaminada con heces. No se trata solo de construir más infraestructura: se trata de operarla mejor, detectar antes y priorizar a quienes están más expuestos.

Mapa de oportunidad: problema, dato y modelo

Problema público	Datos disponibles	Tarea de ML	Métrica clave	Decisión que habilita
Fugas no visibles	Presión, caudal, audio, vibración, reportes ciudadanos.	Clasificación / detección de anomalías.	Recall y costo por fuga detectada.	Enviar brigadas al tramo con mayor probabilidad de fuga.
Calidad inconsistente	pH, turbiedad, cloro residual, conductividad, temperatura.	Clasificación.	F1 y recall de muestras no aptas.	Activar protocolos de tratamiento y muestreo.
Demanda incierta	Consumo histórico, clima, calendario, población.	Regresión / series de tiempo.	MAE, RMSE y MAPE.	Programar bombeo, almacenamiento y mantenimiento.
Servicio desigual	Censo, consumo, reportes, infraestructura, nivel socioeconómico.	Clustering y análisis espacial.	Silhouette + criterio de equidad.	Priorizar inversión en colonias con peor continuidad.
Fallas de infraestructura	Edad, material, suelo, presión, historial de reparaciones.	Clasificación.	AUC-PR y costo esperado.	Sustituir tramos antes de que ocurra la falla.

Caso ilustrativo: detección de fugas con IA acústica

Una fuga no siempre se ve: puede permanecer oculta durante meses bajo el pavimento. Los sensores acústicos capturan el sonido y la vibración que produce el agua al escapar; el reto es distinguir ese patrón del ruido normal de la red. FIDO AI, una tecnología británica utilizada por empresas de agua, entrena redes neuronales profundas con datos acústicos y cinéticos verificados para decidir si hay fuga, estimar su tamaño y priorizar la reparación. La empresa reporta más de 92 % de exactitud en la validación de sus modelos para la decisión fuga / no fuga (FIDO Tech, 2024).

El valor no está solo en la exactitud. En una red con miles de kilómetros, la pregunta operativa es *dónde buscar primero*. Un modelo que reduce el área de búsqueda y ordena las alertas por volumen probable permite que las brigadas trabajen con más impacto por hora. En términos de métricas, esto se traduce en privilegiar el **recall** —detectar la mayor proporción de fugas reales— y aceptar un número controlado de falsas alarmas, siempre que el costo de revisarlas sea menor que el agua perdida.

DEL MODELO A LA DECISIÓN PÚBLICA

Un modelo no cierra una fuga: la cierra una brigada. La IA solo genera una prioridad. Para que esa prioridad se convierta en bien social se necesitan sensores mantenidos, datos compartidos entre áreas, presupuesto de reparación, transparencia en los criterios y un canal para que la ciudadanía reporte lo que el modelo no ve. Sin esa cadena, el mejor modelo se queda en un tablero.

Datos que existen y datos que faltan

DISPONIBLES CON FRECUENCIA

Caudal y presión de estaciones de bombeo, consumo facturado, reportes de fugas, calidad del agua en laboratorio, imágenes satelitales, censos y datos climáticos. En México, el Sistema Nacional de Información del Agua (SINA) y los datos abiertos de CONAGUA ofrecen una base para construir indicadores.

FALTANTES O FRÁGILES

Sensores en redes secundarias, etiquetas verificadas de fugas, ubicación exacta de tuberías antiguas, continuidad del servicio por colonia y datos desagregados de comunidades rurales. Esta ausencia es, en sí misma, un problema de equidad: **lo que no se mide no se prioriza**.

HIPÓTESIS DE TRABAJO PARA LA SECCIÓN 3

Un sistema de apoyo a decisiones que combine clasificación supervisada para detectar fugas y regresión para pronosticar demanda puede reducir el tiempo entre la fuga y la reparación, sobre todo si se complementa con clustering para identificar zonas con servicio más vulnerable. La métrica rectora no debe ser la exactitud global, sino el agua recuperada por cada peso invertido y la reducción de la brecha de servicio.

SECCIÓN 1 · 1.4 · SÍNTESIS

Conclusiones de la Sección 1

"El dato por sí solo no transforma realidades; se convierte en bien social cuando alguien lo usa para decidir mejor y para incluir a quien menos tiene."

01 **El aprendizaje automático es una forma de estimar reglas, no de escribir magia.** Su fundamento es empírico: hay una tarea, una experiencia y una medida de desempeño. Sin datos representativos y sin una métrica alineada con el problema, el modelo carece de valor práctico.

02 **La programación tradicional y el ML no son enemigos.** Las reglas claras deben programarse; el ML se reserva para patrones complejos, cambiantes o difíciles de formalizar. En una red de agua, una tarifa se calcula con una regla y una fuga se estima con un modelo.

03 **Los cinco tipos de aprendizaje responden a señales distintas.** El supervisado aprovecha etiquetas; el no supervisado busca estructura; el refuerzo aprende de la interacción; el semisupervisado reduce el costo de etiquetar; la transferencia reutiliza conocimiento. La elección depende del problema, no de la popularidad del algoritmo.

04 **El agua potable es un dominio de alto impacto y alta exigencia.** Las aplicaciones van desde la detección acústica de fugas y el mantenimiento predictivo hasta la calidad del agua, el pronóstico de demanda y la priorización equitativa. También es un dominio donde los errores tienen consecuencias sanitarias y sociales.

05 **La tecnología no sustituye la gestión pública.** El modelo más útil es el que se integra a una cadena de decisión con sensores, presupuesto, mantenimiento y participación ciudadana. El objetivo no es predecir por predecir, sino recuperar agua y cerrar brechas.

SECCIÓN 1 · 1.5 · APA 7 · CONSULTA: 5 NOV. 2026

Referencias y declaración de uso de IA

Las fuentes web se consultaron el 5 de noviembre de 2026. Se priorizaron libros, documentación oficial de organismos internacionales y artículos revisados por pares.

Comisión Nacional del Agua. (2024). *Situación del subsector agua potable, alcantarillado y saneamiento: Edición 2024*. Secretaría de Medio Ambiente y Recursos Naturales. https://www.gob.mx/cms/uploads/attachment/file/960719/DSAPAS-2024-c.pdf

FIDO Tech. (2024). *FIDO AI: Advanced AI water leak detection*. https://fido.tech/platform/fido-ai/

Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.ª ed.). O'Reilly Media.

IBM. (2024, 20 de septiembre). *What is machine learning?* https://www.ibm.com/think/topics/machine-learning

Kadiwal, A. (2023). *Water potability* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/adityakadiwal/water-potability

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill.

Organización Mundial de la Salud. (2023, 13 de septiembre). *Drinking-water* [Hoja informativa]. https://www.who.int/news-room/fact-sheets/detail/drinking-water

Organización Mundial de la Salud & Fondo de las Naciones Unidas para la Infancia. (2025). *Progress on household drinking water, sanitation and hygiene 2000–2024: Special focus on inequalities*. https://washdata.org/reports/jmp-2025-wash-households

Pekel, J.-F., Cottam, A., Gorelick, N., & Belward, A. S. (2016). High-resolution mapping of global surface water and its long-term changes. *Nature, 540*, 418–422. https://doi.org/10.1038/nature20584

Zavala, D. (2024, 1 de marzo). Se pierde más agua por fugas que la que llega del Cutzamala: UNAM. *Obras Expansión*. https://obras.expansion.mx/infraestructura/2024/03/01/que-porcentaje-de-agua-se-desperdicia-fallas-infraestructura

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL · SECCIÓN 1

En la elaboración de esta sección se utilizó Claude (Anthropic) como asistente para organizar la estructura, mejorar la redacción y maquetar el documento. La herramienta no sustituye el criterio del equipo: las definiciones, los ejemplos, las cifras y las conclusiones fueron revisados y validados por las y los integrantes, y contrastados con las fuentes citadas.

Referencia (APA 7): Anthropic. (2026). *Claude Sonnet 5.5* [Modelo de lenguaje grande]. https://claude.ai
Fecha de uso: 5 de noviembre de 2026. **Responsables de la verificación:** Bernal Najera Alexandra, Marin Flor Julissa, Rosas Toriz Erandy Naomy y Suarez Melonie Magdalena.

SECCIÓN 02
MODELADOS

02

Modelar para decidir

La taxonomía del aprendizaje automático, el ciclo de vida de un modelo, las métricas que importan y la formalización matemática que conecta los datos con la decisión.

2.1 Grafo de taxonomía del ML

2.2 Ciclo de vida de un modelo

2.3 Métricas de evaluación

2.4 Formalización matemática

2.5 Conclusiones de la sección

2.6 Referencias y declaración de IA

“Todos los modelos son incorrectos, pero algunos son útiles.”

GEORGE E. P. BOX · ESTADÍSTICA APLICADA

SECCIÓN 2 · 2.1 · FIGURA 2.1 · ELABORACIÓN PROPIA

Grafo de taxonomía del aprendizaje automático

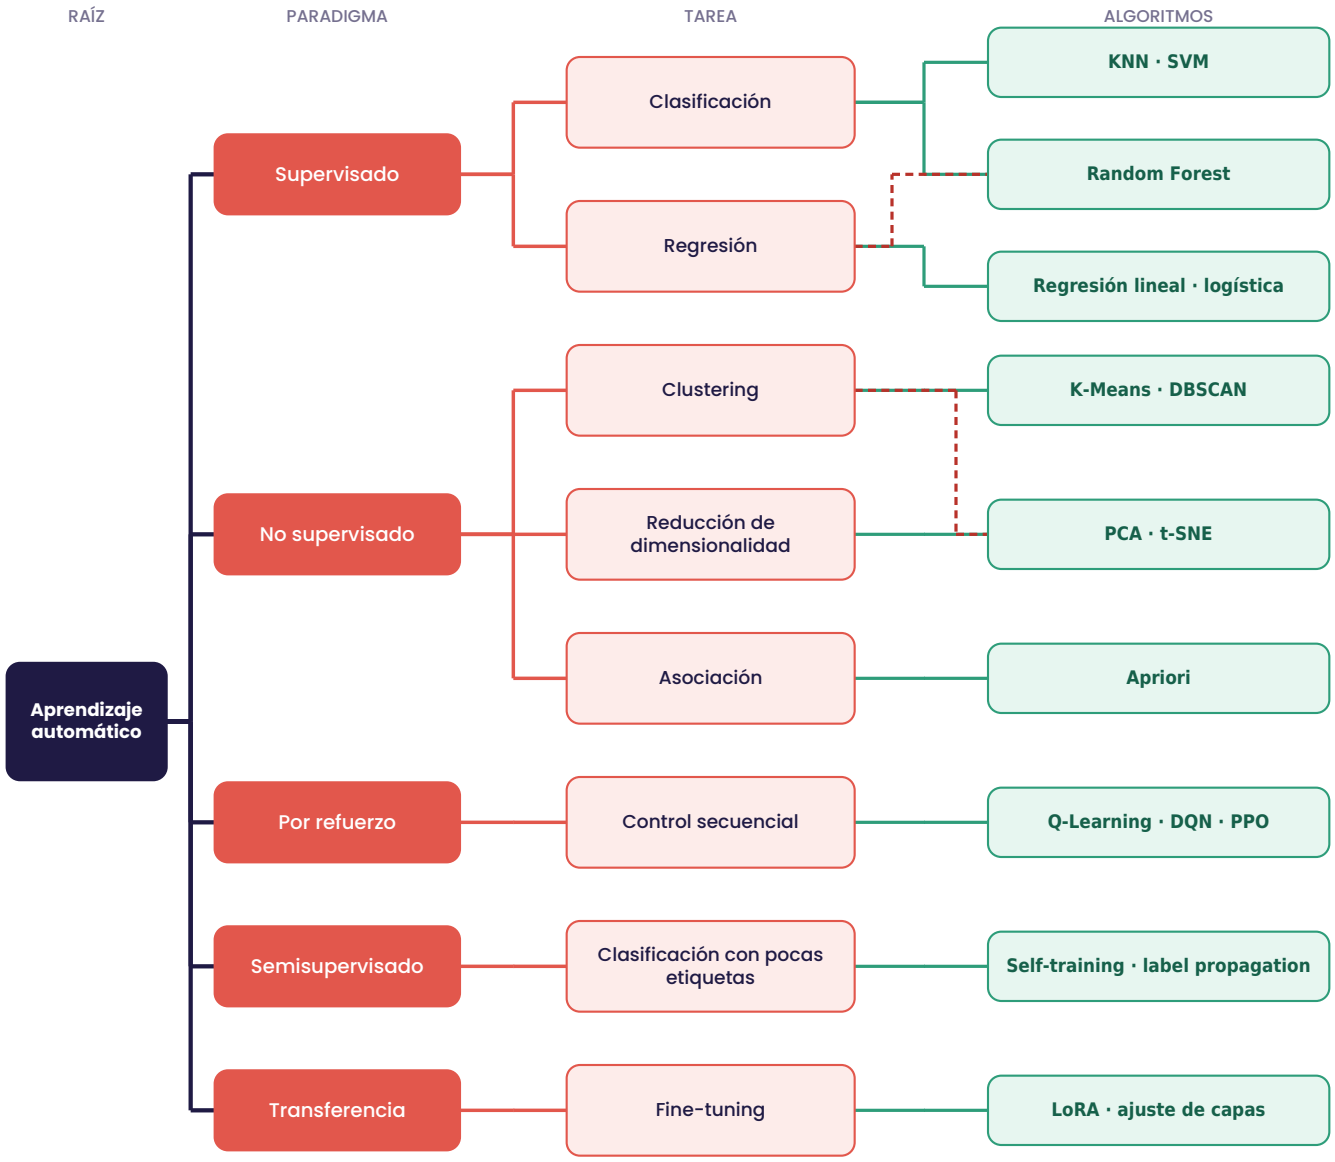


Figura 2.1. Taxonomía del aprendizaje automático con cinco paradigmas, ocho tareas y algoritmos representativos. El nodo raíz *incluye* los paradigmas; cada tarea *es un tipo de* su paradigma; cada tarea *usa* uno o más algoritmos; y las líneas discontinuas muestran algoritmos que *resuelven* más de una tarea (Random Forest: clasificación y regresión; PCA: reducción y preparación para clustering). Elaboración propia con base en Bishop (2006), Géron (2022), Pan y Yang (2010), Sutton y Barto (2018) y Zhu (2005).

2.1.1 Cómo leer la taxonomía

Un grafo de taxonomía no es un catálogo para memorizar: es una herramienta de decisión. Permite ubicar un problema en el paradigma correcto, identificar la tarea y justificar por qué ciertos algoritmos son candidatos razonables.

Relación	Significado	Ejemplo dentro del grafo
incluye	Relación todo-parte entre el nodo raíz y los paradigmas.	El aprendizaje automático incluye aprendizaje supervisado, no supervisado, por refuerzo, semisupervisado y transferencia.
es un tipo de	Especialización: la tarea pertenece a un paradigma.	La clasificación es un tipo de aprendizaje supervisado; el clustering es un tipo de aprendizaje no supervisado.
usa	Selección instrumental: la tarea emplea un algoritmo.	La clasificación usa KNN, SVM o Random Forest; la reducción de dimensionalidad usa PCA o t-SNE.
resuelve	Capacidad adicional: un algoritmo atiende más de una tarea.	Random Forest resuelve clasificación y también regresión; PCA resuelve reducción y preparación de datos para otras tareas.

Por qué la taxonomía importa en un proyecto de agua

El error más común es empezar por el algoritmo (“usemos redes neuronales”) en lugar de por la pregunta. La taxonomía obliga a recorrer el camino inverso: **problema → tarea → paradigma → algoritmo → métrica**.

Pregunta de gestión	Tarea y paradigma	Algoritmos candidatos	Por qué
¿Este tramo tiene una fuga?	Clasificación · supervisado	Random Forest, SVM, gradient boosting	Hay etiquetas históricas de fuga / no fuga y variables de presión, caudal y acústica.
¿Cuánta agua se demandará mañana?	Regresión · supervisado	Regresión lineal regularizada, gradient boosting, series de tiempo	La demanda es continua y depende de clima, calendario y consumo previo.
¿Qué colonias comparten un patrón de riesgo?	Clustering · no supervisado	K-Means, DBSCAN, jerárquico	No hay etiqueta de “vulnerabilidad”; se busca estructura en los datos.
¿Cómo operar las bombas con menos energía?	Control secuencial · refuerzo	Q-Learning, DQN, PPO	Las decisiones de hoy afectan el estado y el costo de mañana.
¿Cómo detectar contaminantes con pocos análisis?	Clasificación · semisupervisado	Self-training, label propagation	El etiquetado de laboratorio es caro; hay muchos datos de sensores sin etiqueta.
¿Cómo reutilizar un modelo en otra ciudad?	Fine-tuning · transferencia	LoRA, ajuste de capas, feature extraction	El dominio cambia, pero parte del conocimiento de la red es reutilizable.

REGLA PRÁCTICA Y CONEXIÓN CON EL AGUA

“Dado un ejemplo, predecir una etiqueta” → supervisado. “Encontrar estructura sin respuesta correcta” → no supervisado. La decisión modifica el entorno y recibe recompensa → refuerzo. Etiquetas escasas → semisupervisado o transferencia. Reglas simples y claras → no uses ML: usa una regla. En agua potable, la rama más madura es la supervisada; la no supervisada aporta contexto de equidad; refuerzo y transferencia son apuestas de mediano plazo.

SECCIÓN 2 · 2.2 · DIAGRAMA DE FLUJO · NUEVE ETAPAS

Ciclo de vida de un modelo de ML

El ciclo de vida describe cómo un modelo pasa de una pregunta a una decisión sostenible. No es una línea recta: la evaluación puede devolver al entrenamiento, el ajuste de hiperparámetros puede repetirse y el monitoreo puede reiniciar la recolección de datos.



Figura 2.2. Ciclo de vida de nueve etapas, leído en serpiente (izquierda→derecha, derecha→izquierda, izquierda→derecha). Elaboración propia.

BUCLE DE MEJORA

Si la evaluación no alcanza el umbral, se vuelve al paso 5 (entrenamiento) o al 7 (ajuste). Si el monitoreo detecta deriva, se reinicia el ciclo en el paso 1. Todo se documenta en una bitácora de experimentos para que cualquier integrante pueda reproducirlo.

Herramientas típicas por etapa

Etapa	Herramientas
01 Recolección	KoboToolbox · Google Forms · Python requests · SINA / CONAGUA · Sentinel Hub
02 Limpieza	pandas · NumPy · OpenRefine · Great Expectations

Etapa	Herramientas
03 División	scikit-learn: train_test_split · KFold · TimeSeriesSplit
04 Selección	scikit-learn · XGBoost · LightGBM · PyTorch · TensorFlow
05 Entrenamiento	scikit-learn · PyTorch Lightning · Keras · MLflow
06 Evaluación	scikit-learn metrics · seaborn · Weights & Biases
07 Ajuste	GridSearchCV · RandomizedSearchCV · Optuna · Ray Tune
08 Despliegue	FastAPI · Docker · Kubernetes · ONNX · AWS / GCP / Azure
09 Monitoreo	Evidently AI · Prometheus / Grafana · MLflow · CloudWatch

EN EL CONTEXTO DEL AGUA

La división temporal es crítica: un modelo de demanda entrenado con datos de 2020–2023 y probado con 2024 puede fallar si cambió el clima o la tarifa. En fugas, la evaluación debe separar por zona y tipo de tubería para no ocultar que el modelo funciona bien en el centro y mal en la periferia. Un buen promedio puede esconder una mala decisión para quien más la necesita.

SECCIÓN 2 · 2.3 · ELEGIR LA MÉTRICA ANTES DE ENTRENAR

Tabla comparativa de métricas de evaluación

Una métrica no es universal: cada tipo de aprendizaje y cada decisión exigen la suya. La tabla organiza las métricas por paradigma, con su fórmula y su lectura en el contexto del agua.

Métrica	Fórmula / definición	Interpretación y ejemplo en agua
SUPERVISADO · CLASIFICACIÓN (etiqueta discreta)		
Exactitud (accuracy)	(TP + TN) / (TP + TN + FP + FN)	Proporción total de aciertos. Engañosa con clases desbalanceadas: con 1 % de fugas, un modelo que siempre dice “no fuga” acierta 99 %.
Precisión	TP / (TP + FP)	De las alertas emitidas, cuántas eran reales. Alta precisión implica menos falsas alarmas y menos viajes innecesarios.
Recall (sensibilidad)	TP / (TP + FN)	De las fugas reales, cuántas se detectaron. Es la métrica prioritaria cuando dejar pasar una fuga cuesta agua y salud.
F1	2 · (P · R) / (P + R)	Media armónica entre precisión y recall. Útil cuando ambas importan y el costo de FP y FN es comparable.
ROC-AUC / PR-AUC	Área bajo la curva TPR vs. FPR / precisión vs. recall	Capacidad de ordenar positivos por encima de negativos. PR-AUC es más informativa con clases muy desbalanceadas.
SUPERVISADO · REGRESIÓN (etiqueta continua)		
MAE	$(1/n)\ \Sigma\ \lvert y_i - \hat{y}_i \rvert$	Error promedio en las mismas unidades de la variable. Fácil de comunicar: “el pronóstico se desvía 3.2 m³”.
RMSE	$\sqrt{[(1/n)\ \Sigma\ (y_i - \hat{y}_i)^2]}$	Penaliza más los errores grandes. Útil si un error extremo de demanda es especialmente costoso.

Métrica	Fórmula / definición	Interpretación y ejemplo en agua
R^2	$1 - SS_{res} / SS_{tot}$	Proporción de variabilidad explicada. Puede ser negativo si el modelo es peor que la media; no mide causalidad.
MAPE	$(100/n)\ \Sigma\ \lvert y_i - \hat{y}_i \rvert / \lvert y_i \rvert$	Error porcentual. Útil para comparar entre zonas, pero inestable cuando la demanda real es cercana a cero.
NO SUPERVISADO (sin etiqueta)		
Silhouette	$(b - a) / \max(a, b)$	Qué tan cohesivo y separado es un punto respecto de otros clusters. Rango −1 a 1; valores altos indican mejor estructura.
Davies-Bouldin	$(1/k)\ \Sigma_i \max_{j \neq i} (s_i + s_j) / d_{ij}$	Promedio de similitud entre cada cluster y su vecino más parecido. Más bajo es mejor.
Inercia (WCSS)	$\Sigma_k \Sigma_{x \in C_k} \lVert x - \mu_k \rVert^2$	Suma de distancias al centroide. Sirve para elegir K con el método del codo, pero siempre disminuye al aumentar K.
Varianza explicada / error de reconstrucción	Varianza retenida por los componentes / $\lVert x - \hat{x} \rVert^2$	En PCA indica cuánta información se conserva; en autoencoders, cuánto se pierde al comprimir y reconstruir.
POR REFUERZO		
Retorno G_t	$\Sigma_{k \geq 0}\ \gamma^k\ r_{t+k}$	Recompensa acumulada con descuento. Mide el objetivo de largo plazo, no la recompensa inmediata.
Recompensa media	$(1/T)\ \Sigma\ r_t$	Desempeño promedio por paso. Útil para comparar políticas en episodios de igual duración.
Regret	Recompensa óptima − recompensa obtenida	Cuánto se pierde por no elegir la mejor acción. En bombas, se traduce en energía o agua no aprovechada.
Tasa de éxito	Episodios exitosos / episodios totales	Proporción de veces que se alcanza la meta (presión mínima, volumen entregado) sin violar restricciones.

Un ejemplo para entender por qué la exactitud no basta

	Predice: fuga	**Predice: no fuga**
Real: fuga	**TP = 16** fugas detectadas	**FN = 4** fugas que pasaron
Real: no fuga	**FP = 24** falsas alarmas	**TN = 956** tramos sanos

Ejemplo ilustrativo (cifras inventadas para enseñar, no son datos reales): 1,000 tramos de tubería, de los cuales 20 tienen fuga.
Exactitud = 972 / 1,000 = **97.2 %**
Precisión = 16 / 40 = **40 %**
Recall = 16 / 20 = **80 %**
F1 = 2 · 0.40 · 0.80 / 1.20 = **0.53**
Un modelo que siempre dijera “no fuga” tendría **98 %** de exactitud y 0 % de recall: por eso la exactitud sola engaña.

REGLA DE ORO

Elige la métrica antes de entrenar y escríbela en el planteamiento. Si la cambias después de ver los resultados, el modelo deja de ser una prueba y se vuelve una justificación.

CLASES DESBALANCEADAS

En fugas, la clase “fuga” suele ser minoritaria. Usa recall, F1, PR-AUC y matrices de confusión; no te quedes con accuracy.

COSTO ASIMÉTRICO

Si una fuga no detectada cuesta 100 y una falsa alarma cuesta 1, el umbral de decisión debe favorecer el recall, aunque aumenten las revisiones.

VALIDACIÓN CORRECTA

Separa por tiempo, zona o tipo de red. Una validación aleatoria puede filtrar información del futuro o de la misma zona y producir métricas optimistas.

MÉTRICA Y DECISIÓN

La métrica técnica no es el objetivo final. El objetivo es agua recuperada, continuidad, calidad y equidad. Traduce siempre el resultado a esas unidades.

SECCIÓN 2 · 2.4 · MODELOS FORMALES · DEL DATO A LA OPTIMIZACIÓN

Formalización matemática del aprendizaje

Formalizar obliga a decir con precisión qué se predice, con qué información, cómo se mide el error y qué se optimiza. Es el puente entre una intuición (“detectar fugas”) y un modelo verificable.

2.4.1 El problema de aprendizaje

Sea un conjunto de datos D con n ejemplos. Cada ejemplo tiene un vector de características x_i en el espacio $\mathbb{R}^d$ y, en aprendizaje supervisado, una etiqueta y_i en el espacio de salida Y. El objetivo es encontrar una función f_θ, parametrizada por θ, que aproxime la relación entre x y y y que generalice a ejemplos no vistos.

PLANTEAMIENTO

Datos: $D = \{ (x_i, y_i) \}_{i=1..n}$, $x_i \in \mathbb{R}^d$, $y_i \in Y$

Modelo: $f_\theta : \mathbb{R}^d \to Y$ (clasificación: probabilidad; regresión: valor continuo)

En agua potable, x puede incluir pH, turbiedad, presión, caudal y edad de la tubería; y puede ser “fuga / no fuga”, “potable / no potable” o demanda en m³.

2.4.2 Riesgo empírico y optimización

El aprendizaje se plantea como un problema de minimización. La función de pérdida L mide el costo de predecir $f_\theta(x_i)$ cuando la respuesta correcta es y_i. El riesgo empírico es el promedio de esa pérdida sobre los datos de entrenamiento. Para evitar el sobreajuste se añade un término de regularización Ω(θ), ponderado por λ.

OPTIMIZACIÓN

Riesgo empírico: $R(\theta) = (1/n) \Sigma_{i=1..n} L(y_i, f_\theta(x_i))$

Objetivo regularizado: $\theta^* = \operatorname{argmin}_\theta [R(\theta) + \lambda \Omega(\theta)]$

Descenso de gradiente: $\theta_{t+1} = \theta_t - \eta \nabla_\theta R(\theta_t)$

η es la tasa de aprendizaje. Ω(θ) puede ser L2 ($\|\theta\|^2$) para suavizar, o L1 ($\|\theta\|_1$) para favorecer modelos dispersos; λ controla el equilibrio entre ajuste y simplicidad.

2.4.3 Pérdidas y objetivos por paradigma

Paradigma / tarea	Objetivo matemático	Pérdida típica	Métrica de evaluación
Supervisado · clasificación	Estimar P(y = c | x)	Entropía cruzada	F1, recall, ROC-AUC, PR-AUC
Supervisado · regresión	Estimar E[y | x]	MSE, MAE, Huber	RMSE, MAE, R^2, MAPE
No supervisado · clustering	Minimizar la distancia intra-cluster	Inercia / WCSS	Silhouette, Davies-Bouldin
No supervisado · reducción	Maximizar varianza explicada o minimizar reconstrucción	Error de reconstrucción	Varianza explicada
Semisupervisado	Combinar pérdida supervisada y consistencia	Supervisada + entropía / consistencia	F1 con pocas etiquetas

Paradigma / tarea	Objetivo matemático	Pérdida típica	Métrica de evaluación
Transferencia	Minimizar pérdida en el dominio destino	Pérdida de la tarea destino	Métricas del dominio destino
Por refuerzo	Maximizar el retorno esperado	Error TD / política	Retorno, regret, tasa de éxito

2.4.4 Ejemplo aplicado: clasificador de fugas

Supongamos que un operador quiere decidir si un tramo tiene una fuga. Con un modelo lineal probabilístico, la probabilidad de fuga se estima con la función logística σ. La pérdida es la entropía cruzada binaria y el umbral de decisión puede bajarse de 0.5 si el costo de una fuga no detectada es mayor que el de una revisión.

CLASIFICADOR LOGÍSTICO

Probabilidad: $p(\text{fuga} \mid x) = \sigma(w \cdot x + b) = 1 / (1 + e^{-(w \cdot x + b)})$

Pérdida: $L = -(1/n)\ \Sigma_i\ [\ y_i \log p_i + (1 - y_i) \log(1 - p_i)\ ]$

Decisión: alertar si $p(\text{fuga} \mid x) \geq \tau$ ($\tau = 0.5$ por defecto; $\tau < 0.5$ si se prioriza el recall)

Las variables x pueden ser presión, caudal, diferencia entre caudal de entrada y salida, edad de la tubería y señal acústica. El umbral τ se ajusta con el costo esperado de falsos positivos y falsos negativos.

2.4.5 Generalización, sesgo y varianza

Un modelo no debe memorizar el entrenamiento: debe generalizar. El error esperado se descompone en sesgo, varianza y ruido irreducible. Un modelo demasiado simple tiene alto sesgo (subajuste); uno demasiado flexible tiene alta varianza (sobreajuste). La regularización, la validación cruzada y más datos ayudan a equilibrar ambos.

SESGO Y VARIANZA

Descomposición del error: $E[\ (y - \hat{f}(x))^2\ ] = \text{Sesgo}(\hat{f})^2 + \text{Varianza}(\hat{f}) + \sigma^2_{\text{ruido}}$

En un modelo de fugas, el sesgo aparece si solo se usan variables de presión y se ignora la edad de la tubería; la varianza aparece si se ajusta un modelo muy complejo con pocos casos etiquetados.

2.4.6 Formulación del aprendizaje por refuerzo

En refuerzo no hay una etiqueta por ejemplo, sino una secuencia de estados, acciones y recompensas. El agente busca una política π que maximice el retorno esperado. La actualización de Q-Learning se apoya en la ecuación de Bellman, que relaciona el valor de una acción con el valor futuro.

REFUERZO

Retorno descontado: $G_t = \Sigma_{k \geq 0}\ \gamma^k\ r_{t+k}$

Q-Learning: $Q(s, a) \leftarrow Q(s, a) + \alpha\ [\ r + \gamma\ \max_{a'} Q(s', a') - Q(s, a)\ ]$

En la operación de bombas, el estado puede ser el nivel del tanque y la demanda; la acción, encender o apagar; la recompensa, el ahorro energético menos la penalización por baja presión.

LO QUE LA FÓRMULA NO DICE

Una ecuación puede tener una solución matemáticamente óptima y, aun así, ser socialmente indeseable. El umbral de decisión, las variables incluidas y la métrica elegida son decisiones humanas. Formalizar no elimina la ética: la hace visible.

SECCIÓN 2 · 2.5 · SÍNTESIS

Conclusiones de la Sección 2

"Modelar es elegir qué simplificar. La responsabilidad está en no simplificar justo aquello que determina quién recibe el agua."

01 **La taxonomía ordena la decisión, no la sustituye.** Ubicar el problema en un paradigma, una tarea y un conjunto de algoritmos evita el "algoritmo de moda" y obliga a justificar la elección con la naturaleza de los datos y del objetivo.

02 **El ciclo de vida es iterativo y sociotécnico.** Recolectar, limpiar, dividir, seleccionar, entrenar, evaluar, ajustar, desplegar y monitorear son etapas conectadas. La calidad de la decisión depende tanto del modelo como de la instrumentación, la documentación y el equipo humano.

03 **No hay una métrica universal.** Clasificación, regresión, clustering y refuerzo requieren métricas distintas. En problemas con clases desbalanceadas o costos asimétricos, la exactitud puede ocultar lo que más importa; el recall, el F1 y el costo esperado suelen ser más honestos.

04 **La formalización conecta el dato con la optimización.** El riesgo empírico, la regularización y el descenso de gradiente explican por qué un modelo aprende y cuándo puede fallar. La descomposición sesgo-varianza y la validación correcta son antídotos contra el autoengaño.

05 **En agua potable, el mejor modelo es el que cambia una decisión.** Detectar fugas, pronosticar demanda o segmentar zonas solo tiene valor si se traduce en reparaciones oportunas, mejor continuidad y menor desigualdad. La métrica final es agua recuperada y servicio más justo.

SECCIÓN 2 · 2.6 · APA 7 · CONSULTA: 5 NOV. 2026

Referencias y declaración de uso de IA

Además de las fuentes de la Sección 1, esta sección se apoya en textos de referencia sobre aprendizaje automático, métricas y aprendizaje por refuerzo.

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631. https://doi.org/10.1145/3292500.3330701

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters, 27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/2106.09685

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A, 374*(2065), 20150202. https://doi.org/10.1098/rsta.2015.0202

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., … Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature, 518*(7540), 529–533. https://doi.org/10.1038/nature14236

Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering, 22*(10), 1345–1359. https://doi.org/10.1109/TKDE.2009.191

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.ª ed.). MIT Press.

Zaharia, M., Chen, A., Davidson, A., Ghodsi, A., Hong, S. A., Konwinski, A., … Zumar, C. (2018). Accelerating the machine learning lifecycle with MLflow. *IEEE Data Engineering Bulletin, 41*(4), 39–45.

Zhu, X. (2005). *Semi-supervised learning literature survey* (Technical Report 1530). University of Wisconsin-Madison.

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL · SECCIÓN 2

En la elaboración de esta sección se utilizó Claude (Anthropic) como apoyo para estructurar la taxonomía, revisar la consistencia de las relaciones del grafo, proponer ejemplos de métricas y generar los diagramas. La herramienta no sustituye el criterio del equipo: las definiciones, los ejemplos, las cifras y las conclusiones fueron revisados y validados por las y los integrantes, y contrastados con las fuentes citadas.

Referencia (APA 7): Anthropic. (2026). *Claude Sonnet 5.5* [Modelo de lenguaje grande]. https://claude.ai
Fecha de uso: 5 de noviembre de 2026. **Responsables de la verificación:** Bernal Najera Alexandra, Marin Flor Julissa, Rosas Toriz Erandy Naomy y Suarez Melonie Magdalena.

CIERRE · 03 · INTEGRACIÓN DE LAS SECCIONES 1 Y 2

Conclusiones generales

A lo largo de las dos secciones, el documento pasó de la definición abstracta a la representación formal de un problema concreto. La conclusión central es que el aprendizaje automático no produce bien social por sí mismo: produce **evidencia** que, integrada a una cadena de decisión, puede mejorar quién recibe agua, con qué continuidad y a qué costo.

> *"El dato se convierte en bien social cuando alguien lo usa para decidir mejor y para incluir a quien menos tiene. Ese es el paso que este documento prepara y que la Sección 3 deberá demostrar."*

01 **Comprender el ML exige abandonar la idea de que la máquina "sabe".** Un modelo estima regularidades a partir de ejemplos y las evalúa con una medida de desempeño. No hay conocimiento sin datos representativos, sin una tarea bien definida y sin una métrica que refleje la decisión real.

02 **La clasificación por tipos de aprendizaje es una herramienta de decisión, no un catálogo.** En el acceso al agua potable, la rama supervisada ofrece la ruta más madura para detectar fugas, estimar demanda y clasificar calidad; las demás ramas aportan contexto, optimización operativa y capacidad de adaptación.

03 **Modelar es hacer explícitas las decisiones que suelen quedar ocultas.** El grafo obliga a justificar el paradigma y la tarea; el ciclo de vida muestra la dependencia de la recolección, la limpieza, el despliegue y el monitoreo; la tabla de métricas revela que ninguna medida es universal; y la formalización conecta el dato con la optimización y sus límites.

04 **En problemas sociales, la métrica técnica debe traducirse a una métrica de bienestar.** Un recall alto en fugas solo importa si se convierte en reparaciones oportunas. La evaluación debe incluir a los grupos con peor acceso, no solo el promedio de la red.

05 **El acceso al agua potable es un caso exigente y, por ello, un buen laboratorio de ética aplicada.** Los datos faltantes suelen corresponder a las comunidades con mayor rezago; los sensores se concentran donde ya hay infraestructura. Un proyecto responsable debe declarar esas asimetrías y diseñar mecanismos para corregirlas.

06 **La Sección 3 deberá cerrar el argumento con una propuesta concreta.** Combinará clasificación supervisada para fugas, regresión para demanda y análisis de conglomerados para equidad, con una métrica rectora: agua recuperada por cada peso invertido y reducción de la brecha de servicio. Esa será la hipótesis que se defenderá en la entrega manuscrita.

RESPUESTA A LA PREGUNTA GUÍA

El tipo de aprendizaje más adecuado para transformar los datos de un sistema de agua potable en decisiones que reduzcan pérdidas y mejoren la equidad es, principalmente, el **supervisado** —clasificación para fugas y calidad, regresión para demanda—, complementado con aprendizaje **no supervisado** para segmentar zonas vulnerables. El refuerzo y la transferencia quedan como apuestas de mediano plazo, condicionadas a la instrumentación y a la capacidad operativa del organismo.

CIERRE · 04 · FORMATO APA 7 · CONSULTA: 5 DE NOVIEMBRE DE 2026

Referencias consolidadas

Esta lista reúne las fuentes citadas en las Secciones 1 y 2, ordenadas alfabéticamente. Las fuentes web se consultaron el 5 de noviembre de 2026. Los conjuntos de datos y la documentación técnica se identifican con su tipo entre corchetes. Las herramientas de IA generativa utilizadas se declaran al final de cada sección; la selección de fuentes, la verificación de datos y la redacción final son responsabilidad del equipo.

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631. https://doi.org/10.1145/3292500.3330701

Anthropic. (2026). *Claude Sonnet 5.5* [Modelo de lenguaje grande]. https://claude.ai

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Comisión Nacional del Agua. (2024). *Situación del subsector agua potable, alcantarillado y saneamiento: Edición 2024*. Secretaría de Medio Ambiente y Recursos Naturales. https://www.gob.mx/cms/uploads/attachment/file/960719/DSAPAS-2024-c.pdf

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters, 27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

FIDO Tech. (2024). *FIDO AI: Advanced AI water leak detection*. https://fido.tech/platform/fido-ai/

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.ª ed.). O'Reilly Media.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/2106.09685

IBM. (2024, 20 de septiembre). *What is machine learning?* https://www.ibm.com/think/topics/machine-learning

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A, 374*(2065), 20150202. https://doi.org/10.1098/rsta.2015.0202

Kadiwal, A. (2023). *Water potability* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/adityakadiwal/water-potability

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., … Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature, 518*(7540), 529–533. https://doi.org/10.1038/nature14236

Organización Mundial de la Salud & Fondo de las Naciones Unidas para la Infancia. (2025). *Progress on household drinking water, sanitation and hygiene 2000–2024: Special focus on inequalities*. https://washdata.org/reports/jmp-2025-wash-households

Organización Mundial de la Salud. (2023, 13 de septiembre). *Drinking-water* [Hoja informativa]. https://www.who.int/news-room/fact-sheets/detail/drinking-water

Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering, 22*(10), 1345–1359. https://doi.org/10.1109/TKDE.2009.191

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Pekel, J.-F., Cottam, A., Gorelick, N., & Belward, A. S. (2016). High-resolution mapping of global surface water and its long-term changes. *Nature, 540*, 418–422. https://doi.org/10.1038/nature20584

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.ª ed.). MIT Press.

Zaharia, M., Chen, A., Davidson, A., Ghodsi, A., Hong, S. A., Konwinski, A., … Zumar, C. (2018). Accelerating the machine learning lifecycle with MLflow. *IEEE Data Engineering Bulletin, 41*(4), 39–45.

Zavala, D. (2024, 1 de marzo). Se pierde más agua por fugas que la que llega del Cutzamala: UNAM. *Obras Expansión*. https://obras.expansion.mx/infraestructura/2024/03/01/que-porcentaje-de-agua-se-desperdicia-fallas-infraestructura

Zhu, X. (2005). *Semi-supervised learning literature survey* (Technical Report 1530). University of Wisconsin-Madison.

CIERRE · 05 · ANEXO A · EQUIPO G171

Roles del equipo y declaración de originalidad

El trabajo se organizó por bloques con revisión cruzada: cada integrante redactó una parte y verificó la de otra persona. Las decisiones de contenido se tomaron en sesión de equipo y se documentaron en una bitácora interna.

Distribución de responsabilidades

Integrante	Responsabilidad principal	Revisión cruzada
Bernal Najera Alexandra	Coordinación general, investigación conceptual (1.1) y verificación de definiciones.	Revisión de métricas y formalización matemática (2.3–2.4).
Marin Flor Julissa	Clasificación del aprendizaje y aplicaciones reales (1.2); edición y diseño editorial del documento.	Revisión del grafo de taxonomía y del ciclo de vida (2.1–2.2).
Rosas Toriz Erandy Naomy	Contexto social y vínculo con el acceso al agua potable (1.3); conclusiones de la Sección 1.	Revisión de referencias y declaración de IA de la Sección 2.
Suarez Melonie Magdalena	Taxonomía, ciclo de vida y tabla de métricas (2.1–2.3); verificación de fórmulas.	Revisión de la Sección 1 y de las referencias consolidadas.

Declaración de originalidad

DECLARACIÓN DEL EQUIPO

Declaramos que este documento es de elaboración propia y que no se copiaron fragmentos de fuentes externas ni de herramientas de inteligencia artificial sin reelaboración. Las citas textuales, cuando aparecen, están entre comillas y referenciadas en formato APA 7. Las figuras, tablas y diagramas fueron elaborados por el equipo o generados con software declarado; los datos numéricos provienen de las fuentes citadas y fueron verificados antes de su inclusión.

Reconocemos el uso de herramientas de IA generativa como apoyo de estructura, redacción y diseño, según se detalla al final de cada sección, y asumimos la responsabilidad sobre el contenido final, incluidos sus errores u omisiones.

Bernal Najera Alexandra
Integrante · Equipo G171

Marin Flor Julissa
Integrante · Equipo G171

Rosas Toriz Erandy Naomy
Integrante · Equipo G171

Suarez Melonie Magdalena
Integrante · Equipo G171

Aguilar Bello Rogerio
Integrante · Equipo G171

Lista de verificación de la actividad

Requisito de la actividad	Dónde se cumple	Estado
Portada, índice, contenido y conclusiones.	Portada, contenido, secciones 1–2 y cierre.	CUMPLIDO
Definición propia y al menos dos definiciones citadas.	1.1.1 y tabla de definiciones.	CUMPLIDO
Diferencia entre programación tradicional y ML.	1.1.1, diagrama y tabla comparativa.	CUMPLIDO
Dataset, etiqueta, feature y función de pérdida.	1.1.2 y fórmulas de pérdida.	CUMPLIDO

Requisito de la actividad	Dónde se cumple	Estado
Al menos 10 aplicaciones reales en tabla.	1.2.2, tabla de 13 aplicaciones.	CUMPLIDO
Grafo de taxonomía con niveles y relaciones.	2.1, Figura 2.1 y leyenda.	CUMPLIDO
Diagrama de flujo del ciclo de vida con 9 etapas.	2.2, Figura 2.2.	CUMPLIDO
Tabla comparativa de métricas por tipo de ML.	2.3, tabla por paradigma.	CUMPLIDO
Referencias APA 7 y fecha de consulta.	1.5, 2.6 y referencias consolidadas.	CUMPLIDO
Declaración de uso de IA al final de cada sección.	1.5 y 2.6.	CUMPLIDO
Sección 3 manuscrita.	Entrega física independiente.	FUERA DE ESTE PDF

CIERRE · 06 · ANEXO B · EQUIPO G171

Anexo B. Diagramas y tablas complementarios

Este anexo amplía las Secciones 1 y 2 con diagramas de flujo de decisión y de proceso, una arquitectura de datos, una simulación del umbral de decisión y tablas de apoyo (algoritmos, riesgos e indicadores). Todas las figuras son de elaboración propia; las cifras de simulación son ilustrativas y se indican como tales.

Anexo A (continuación) · Integrante incorporado

Integrante	Responsabilidad principal	Revisión cruzada
Aguilar Bello Rogerio	Diagramas de flujo, arquitectura de datos y tablas complementarias (Anexo B); verificación de referencias del anexo.	Revisión del grafo de taxonomía y de la tabla de métricas (2.1–2.3).

B.1 Flujo de decisión: ¿qué tipo de aprendizaje elegir?

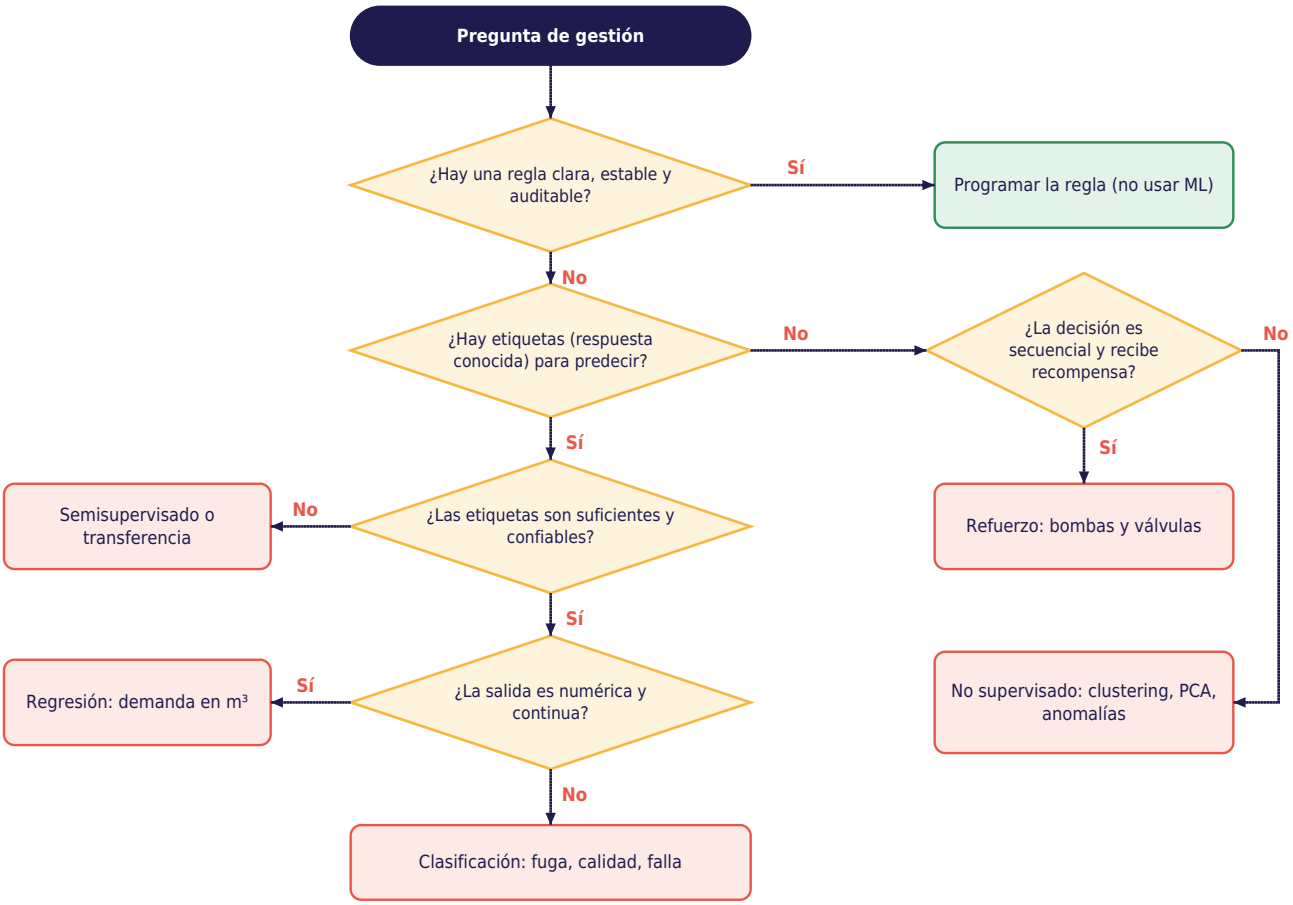


Figura B.1. Diagrama de flujo de decisión para ubicar un problema en un paradigma de aprendizaje. Rombos: decisiones; rectángulos: resultados. Elaboración propia con base en Bishop (2006), Géron (2022), Sutton y Barto (2018) y Zhu (2005).

ANEXO B · B.2 · DIAGRAMA DE FLUJO DE PROCESO

Del sensor a la reparación

Proceso operativo de detección de fugas con tres carriles de responsabilidad y un bucle de retroalimentación que reentrena el modelo con etiquetas verificadas en campo.

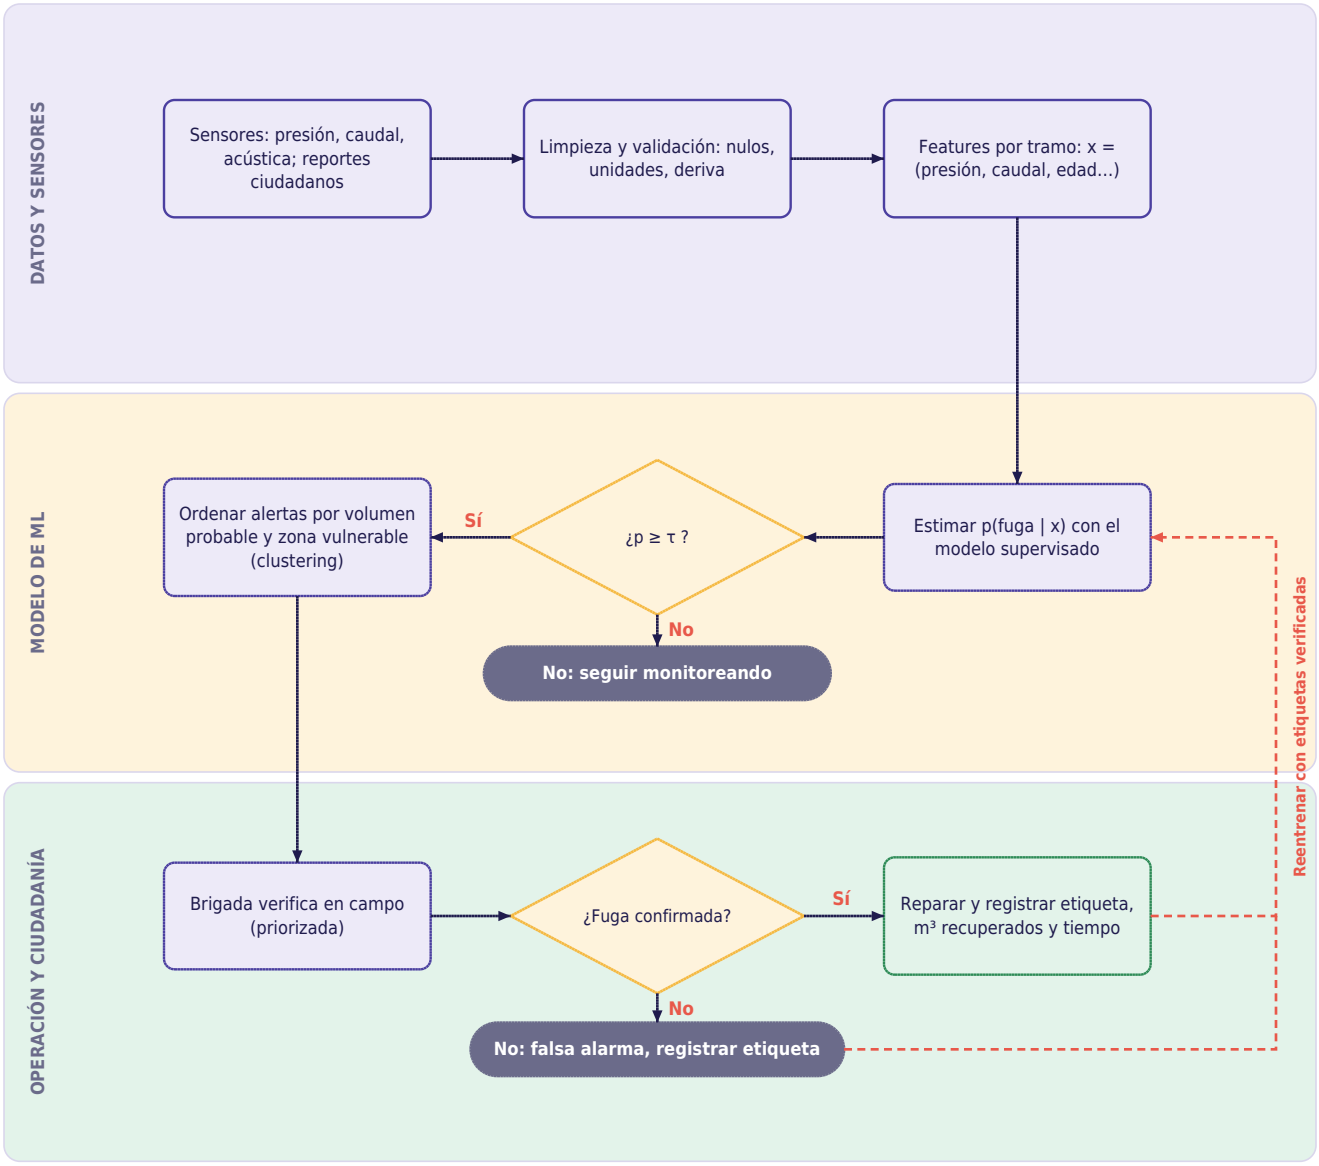


Figura B.2. Flujo operativo de detección de fugas. Línea discontinua roja: bucle de mejora (etapas 7 y 9 del ciclo de vida, Figura 2.2). τ: umbral de decisión. Elaboración propia con base en Chandola et al. (2009), Géron (2022) y Sculley et al. (2015).

B.3 Indicadores de seguimiento del proceso

Indicador	Definición	Frecuencia
Tiempo fuga-reparación (días)	Fecha de reparación − fecha de detección, por tramo y por zona.	Semanal
Agua recuperada (m³/mes)	Caudal de fuga estimado × días de fuga evitados.	Mensual
Tasa de falsas alarmas	FP / (TP + FP) = 1 − precisión de las alertas revisadas.	Semanal
Cobertura por zona	Tramos monitoreados / tramos totales; revela zonas sin datos.	Trimestral

ANEXO B · B.4 · ARQUITECTURA DE DATOS

De las fuentes a la decisión

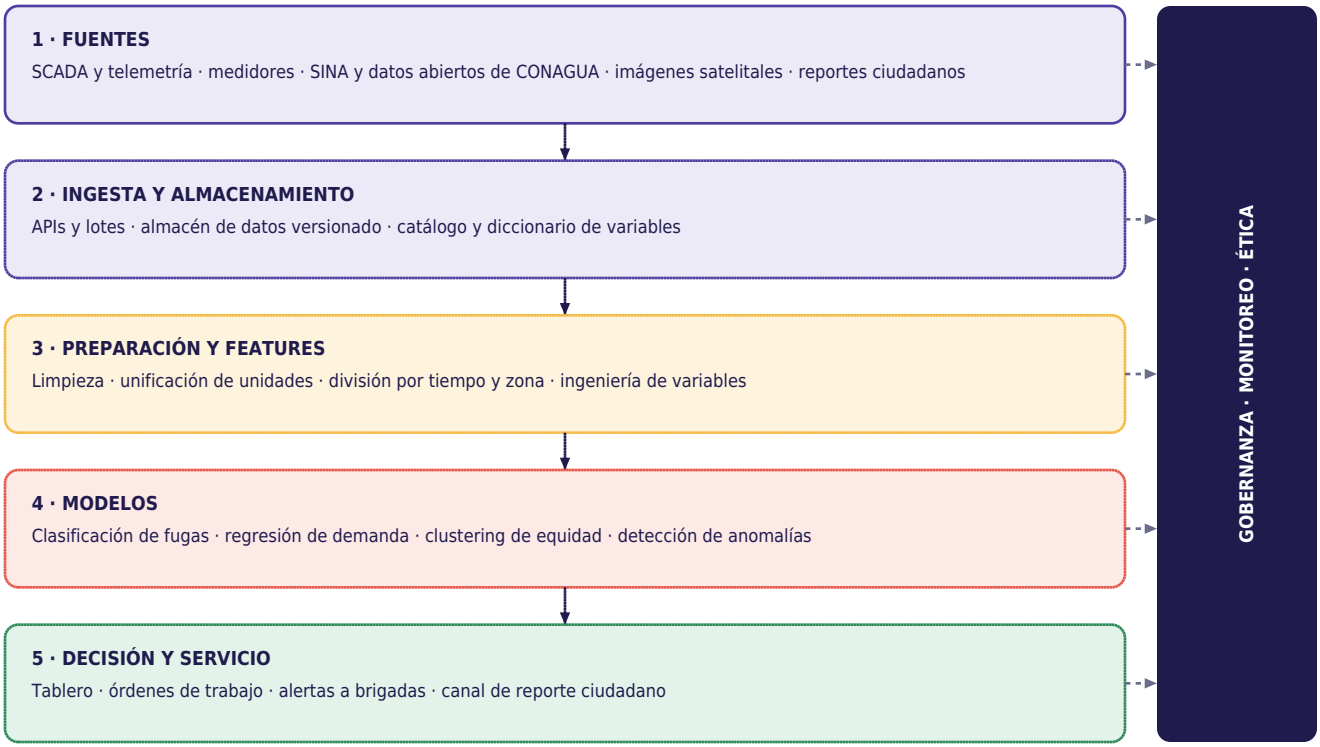


Figura B.3. Arquitectura de cinco capas para un sistema de apoyo a decisiones hídricas. La barra lateral indica controles transversales: vigilancia de deriva, auditoría de sesgo, transparencia de criterios y trazabilidad de versiones. Elaboración propia con base en Sculley et al. (2015) y Zaharia et al. (2018).

B.5 Simulación: efecto del umbral de decisión

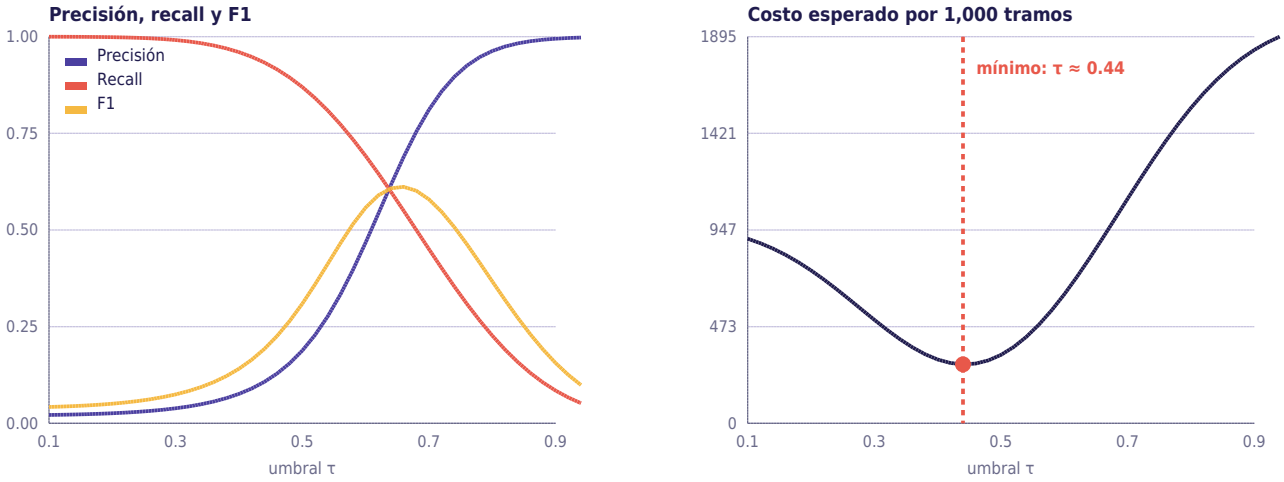


Figura B.4. Simulación ilustrativa (no son datos reales): puntajes normales N(0.68, 0.16) para fugas y N(0.30, 0.14) para tramos sanos; prevalencia de fugas 2 %; costo de una fuga no detectada = 100 y de una falsa alarma = 1. El costo mínimo ocurre con un umbral menor que 0.5, como se explicó en 2.4.4. Elaboración propia con base en Fawcett (2006) y Saito y Rehmsmeier (2015).

ANEXO B · B.6 · TABLA DE ALGORITMOS

Candidatos y riesgos

B.6 Algoritmos candidatos para el caso del agua

Algoritmo	Tarea	Fortalezas	Limitaciones	Interpretación
Regresión logística	Clasificación	Rápida, calibra probabilidades y sirve como línea base (baseline).	Supone fronteras lineales; requiere escalar variables.	Alta
Random Forest	Clasificación / regresión	Maneja variables mixtas y no linealidades; robusto al ruido (Breiman, 2001).	Menos preciso con datos muy dispersos; modelo grande.	Media
Gradient boosting (XGBoost)	Clasificación / regresión	Alto desempeño en datos tabulares (Chen y Guestrin, 2016).	Sensible a hiperparámetros; riesgo de sobreajuste.	Media
SVM	Clasificación	Eficaz con pocas muestras y muchas variables (Bishop, 2006).	Escala mal con muchos registros; poco interpretable.	Baja
K-Means / DBSCAN	Clustering	Segmenta zonas sin etiquetas; DBSCAN detecta ruido y anomalías.	Requiere elegir K o ε; sensible a la escala.	Media
Q-Learning / DQN	Control secuencial	Optimiza decisiones en el tiempo (Sutton y Barto, 2018; Mnih et al., 2015).	Necesita simulador o datos de interacción; entrenamiento inestable.	Baja

Tabla B.1. Comparación de algoritmos candidatos. Interpretabilidad: capacidad de explicar una predicción a una persona no técnica. Elaboración propia con base en las fuentes citadas.

B.7 Riesgos del modelo y mitigaciones

Riesgo	Cómo se manifiesta en agua potable	Mitigación	Etapa
Sesgo de muestreo	Hay sensores donde ya existe infraestructura; las colonias periféricas casi no aparecen (Mehrabi et al., 2021).	Medir y reportar desempeño por zona; sensores móviles o muestreo dirigido.	1, 6
Fuga de información	Una división aleatoria mezcla datos del futuro o de la misma zona y infla las métricas (Kohavi, 1995).	Dividir por tiempo, zona o tipo de red; validación cruzada por bloques.	3
Deriva de datos	Cambian el clima, la tarifa o el sensor y el modelo pierde desempeño (Gama et al., 2014).	Monitorear distribuciones y métricas; reentrenar con umbrales definidos.	9
Clases desbalanceadas	Las fugas son pocas; la exactitud alta oculta un recall nulo.	Usar recall, F1 y PR-AUC; ponderar clases; ajustar τ por costo.	6, 7
Opacidad	La brigada o la ciudadanía no entienden por qué se prioriza una colonia.	Publicar criterios; explicar con variables importantes; bitácora de experimentos.	4, 8
Deuda técnica	Scripts sin versionar, datos sin trazabilidad, modelos que nadie mantiene (Sculley et al., 2015).	Versionar datos, código y modelo; automatizar con MLflow o equivalente.	8, 9

Tabla B.2. Riesgos frecuentes y su mitigación. «Etapa» remite a las nueve etapas del ciclo de vida (Figura 2.2). Elaboración propia con base en las fuentes citadas.

ANEXO B · B.8 · DE LA MÉTRICA AL BIENESTAR

Indicadores y referencias

B.8 Traducción de métricas técnicas a métricas de bienestar

Métrica técnica	Traducción operativa	Métrica de bienestar	Quién decide
Recall de fugas	Fugas reales detectadas a tiempo.	m³ recuperados por mes.	Operador de agua
Precisión de alertas	Viajes de brigada que sí encuentran fuga.	Horas de brigada bien usadas.	Operador de agua
MAPE de demanda	Error del pronóstico por zona.	Horas sin agua evitadas por mala programación.	Operador y municipio
Silhouette de clusters	Zonas con patrón de servicio similar.	Brecha de continuidad entre colonias.	Municipio y comunidad
F1 de calidad del agua	Muestras no aptas identificadas.	Hogares con agua apta verificada.	Salud pública

Tabla B.3. Del indicador técnico al resultado social. Elaboración propia con base en WHO y UNICEF (2025) y Mehrabi et al. (2021).

Referencias del Anexo B (APA 7) · consulta: 6 de noviembre de 2026

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. ACM Computing Surveys, 41(3), 1–58. https://doi.org/10.1145/1541880.1541882

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. ACM Computing Surveys, 46(4), 1–37. https://doi.org/10.1145/2523813

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. Proceedings of the 14th International Joint Conference on Artificial Intelligence, 1137–1143.

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. ACM Computing Surveys, 54(6), 1–35. https://doi.org/10.1145/3457607

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., … Dennison, D. (2015). Hidden technical debt in machine learning systems. Advances in Neural Information Processing Systems, 28, 2503–2511.

Además se usan, ya listadas en las referencias consolidadas: Bishop (2006), Fawcett (2006), Géron (2022), Mnih et al. (2015), Organización Mundial de la Salud y UNICEF (2025), Sutton y Barto (2018), Zaharia et al. (2018) y Zhu (2005).

> DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL · ANEXO B
>
> En la elaboración de este anexo se utilizó Claude (Anthropic) como apoyo para diseñar los diagramas de flujo, la arquitectura, la simulación del umbral y las tablas, y para maquetar las páginas. Las cifras de la simulación son ilustrativas. El contenido fue revisado y validado por las y los integrantes, y contrastado con las fuentes citadas.
>
> *Referencia (APA 7): Anthropic. (2026). Claude Sonnet 5.5 [Modelo de lenguaje grande]. https://claude.ai · Fecha de uso: 6 de noviembre de 2026. Responsables de la verificación: Bernal Najera Alexandra, Marin Flor Julissa, Rosas Toriz Erandy Naomy, Suarez Melonie Magdalena y Aguilar Bello Rogerio.*